

Домашняя работа №2 Дедлайн 23 февраля 2025 17:59

В этой домашке мы работаем с теми же самыми данными, что и в первом домашнем задании, и задача для обучения модели стоит точно такая же. Прочтите описание данных и задачи ниже.

Однако мы будем работать с данными используя только Hive.

За основу взят датасет и соревнование [Criteo Display Advertising challenge](#)

Задание

Предскажите вероятность клика на рекламный баннер. Признаки включают в себя некоторое количество целочисленных и категориальных переменных. Данные в обучающем датасете покрывают 7 последовательных дней, данные валидационного датасета покрывают 8-ой день.

Первая колонка датасета - идентификатор записи - целое число. Вторая - целевая переменная: 1 - клик, 0 - нет клика. Следующие 13 - целочисленные признаки, имеются пропуски. Следующие 26 - категориальные признаки, так же имеются пропуски.

Для простоты, возьмите следующее определение полей датасета:

```
numeric_features = ["if"+str(i) for i in range(1,14)]  
categorical_features = ["cf"+str(i) for i in range(1,27)]
```

```
fields = ["id", "label"] + numeric_features + categorical_features
```

Метрика - Log loss (http://wiki.fast.ai/index.php/Log_Loss).

Более подробное описание задачи можно найти на сайте соревнования по ссылке выше. Вы можете пользоваться моделями, описанными на форуме соревнования, искать среди них идеи, но ваше решение все равно должно укладываться в заданные рамки оформления работы, см. Ниже.

Датасеты

Обучающий

Обучающий датасет расположен в локальной файловой системе на вашем login-узле:

`/home/users/datasets/criteo/train1000.txt`

Тестовый датасет для работы со срезами.

Это большой, на 11 Гб датасет, на котором можно применять условия фильтрации.

HDFS: `/datasets/criteo/testdir`

Обратите внимание, что путь к датасету другой, хотя это тот же самый датасет `test-with-id.txt`. Это обусловлено особенностями hive - он проверяет возможность записи в директорию с датасетом, для которого создается внешняя таблица, даже если не собирается туда писать

Что делать

Приготовьте и положите в репо в подпапку `projects/2a` следующие скрипты `.hql`:

- `create_test.hql` - создание внешней таблицы `hw2_test` с тестовым датасетом `/datasets/criteo/testdir`. Таблица должна быть `temporary external`.
- `create_pred.hql` - создание `managed` таблицы `hw2_pred` для предсказаний. В качестве `location` укажите `<ваш логин>_hw2_pred`. В этой таблице должны быть две колонки - для `id` записи, и для предсказания.
- `filter_predict.hql` - наполнение таблицы `hw2_pred` путем запроса с фильтрацией по заданному условию `20 < if1 < 40` и одновременным предсказанием модели на фильтрованных данных.
- `select_out.hql` - выгрузка данных из таблицы `hw2_pred` в текстовом виде в относительный (без начального `/`) путь `<ваш логин>_hiveout` в HDFS.

Кроме того, включите файлы `model.py`, `train.py`, `train.sh`, `predict.py`. После тренировки модели, она должна сохраняться в `2a.joblib`.

Проверка

Запустите:

checker.sh 2a

- Последовательно выполнит ваши скрипты и проверит их результат.
- скачает из HDFS файл <ваш логин>_hiveout и рассчитает метрику

Чекер выполняется из корня вашего репо. Команды Hive будут подаваться вот таким образом, где NAME_ - ваш логин с тире (-) замененным на подчеркик (_):

```
create database if not exists ${NAME_}_checker;  
use ${NAME_}_checker;  
drop table hw2_test;  
source projects/2a/create_test.hql;  
describe hw2_test;  
select count(id) from hw2_test;  
drop table hw2_pred;  
source projects/2a/create_pred.hql;  
describe hw2_pred;  
source projects/2a/filter_predict.hql;  
select count(id) from hw2_pred;  
source projects/2a/select_out.hql;
```

Подсказки

Обратите внимание, как Hive обрабатывает пропущенные значения.

Зачет

Зачет при метрике лучше, чем 1.99, то есть <1.99. Если не добились этого сора (чекер показывает PASSED 0), то работу все равно зачетом.

Добейтесь PASSED 1 (или 0 при наличии сора) от чекера.